ECOLE NATIONALE DE COMMERCE ET DE GESTION

Filière : Finance

COMPTE RENDU DE PROJET

Theme : Credit Bancaire & Scoring

Prediction du Montant de Credit Accorde

Modeles : Regression Lineaire | Ridge | Lasso | ElasticNet

Dataset : Loan Prediction Dataset (Kaggle) — Contexte bancaire marocain

Annee universitaire : 2025 – 2026

Membres du Groupe

Jnayni douaa
24010271

Mbarki Fatima Zahra
24010348

Basma Jaoui
22005987

Sommaire

Résumé Exécutif

1. **Introduction**
2. **Présentation des Données**
3. **Prétraitement des Données**
4. **Analyse Exploratoire des Données (EDA)**
5. **Feature Engineering et Encodage**
6. **Modélisation**
7. **Évaluation et Comparaison des Modèles**
8. **Interprétation des Résultats**
9. **Prédiction sur un Nouveau Client**
10. **Conclusion**

Résumé Exécutif

Synthèse du projet

Ce projet de data science applique des techniques de régression supervisée pour prédire le montant d'un crédit bancaire (LoanAmount) en Dirhams Marocains (MAD). En s'appuyant sur un dataset de 614 demandes de prêt, quatre modèles ont été entraînés et comparés : Régression Linéaire, Ridge, Lasso et ElasticNet. Les résultats montrent que les variables de revenu (revenu du demandeur et du co-demandeur) constituent les déterminants les plus puissants du montant accordé. Le meilleur modèle obtenu atteint un coefficient de détermination R^2 proche de 0,50 sur le jeu de test, avec une erreur absolue moyenne (MAE) d'environ 22 000 MAD.

1. Introduction

1.1 Contexte : Le crédit bancaire et le scoring

Le crédit bancaire constitue l'un des piliers fondamentaux du financement de l'économie. Il permet aux ménages d'acquérir un logement, de financer leurs études ou de faire face à des dépenses imprévues. Pour les banques, accorder un prêt représente toutefois un risque financier important : le risque que l'emprunteur ne rembourse pas sa dette, communément appelé **risque de crédit**. Afin de gérer ce risque, les institutions financières ont développé des modèles de **scoring** — des systèmes d'évaluation qui attribuent à chaque client un score reflétant sa capacité et sa volonté de rembourser.

Au Maroc, le secteur bancaire est régulé par Bank Al-Maghrib (BAM), la banque centrale, qui impose des normes prudentielles strictes aux établissements de crédit. Dans ce contexte, l'automatisation et la standardisation des décisions de crédit grâce à l'intelligence artificielle et au machine learning offrent des avantages considérables : rapidité de traitement, objectivité des décisions, et meilleure gestion du risque.

1.2 Problématique

Question centrale du projet

À partir des caractéristiques socio-économiques et financières d'un demandeur de prêt (revenus, situation familiale, historique de crédit, zone géographique...), est-il possible de prédire avec précision le montant du crédit qui lui sera accordé ?

Cette question est essentielle pour une banque car elle touche à la fois à la satisfaction client (proposer un montant adapté aux besoins) et à la maîtrise du risque (ne pas octroyer un montant excessif par rapport aux capacités de remboursement). Un modèle prédictif fiable permet d'optimiser les deux.

1.3 Objectifs du projet

Ce projet poursuit les objectifs suivants :

- Explorer et comprendre les données de demandes de prêt bancaire dans un contexte marocain.
- Nettoyer et préparer les données pour la modélisation (imputation, encodage, transformation).
- Construire et comparer quatre modèles de régression supervisée.
- Évaluer les performances de chaque modèle à l'aide de métriques standards (R^2, RMSE, MAE).
- Interpréter les résultats pour extraire des conclusions économiques pertinentes.
- Simuler la prédiction du montant de crédit pour un nouveau client type.

2. Présentation des Données

2.1 Source des données

Le dataset utilisé est inspiré du Loan Prediction Dataset, disponible sur la plateforme Kaggle. Ce jeu de données, initialement conçu pour un contexte indien, a été adapté au marché bancaire marocain : les montants en roupies (INR) ont été convertis en Dirhams Marocains (MAD) en appliquant le taux de conversion 1 INR ≈ 0,12 MAD. Le dataset final comprend 614 observations et 15 variables.

2.2 Description des variables

Variables catégorielles

Variable	Type	Description	Modalités
Gender	Binaire	Genre du demandeur	Male / Female
Married	Binaire	Situation matrimoniale	Yes / No
Dependents	Ordinale	Nombre de personnes à charge	0 / 1 / 2 / 3+
Education	Binaire	Niveau d'éducation	Graduate / Not Graduate
Self_Employed	Binaire	Statut professionnel	Yes / No
Property_Area	Nominale	Zone géographique du bien	Urban / Semiurban / Rural
Loan_Status	Binaire	Statut de la demande	Y (acceptée) / N (refusée)

Variables numériques

Variable	Unité	Description
ApplicantIncome	INR / MAD	Revenu mensuel du demandeur principal
CoapplicantIncome	INR / MAD	Revenu mensuel du co-demandeur (conjoint, garant...)
LoanAmount	INR (×1000) / MAD	Montant du prêt demandé — variable cible
Loan_Amount_Term	Mois	Durée de remboursement du prêt
Credit_History	0 ou 1	Historique de crédit : 1 = bon, 0 = défaillant

2.3 Taille du dataset

Le dataset contient 614 lignes (demandes de prêt) et 15 colonnes (variables). Après suppression de l'identifiant unique Loan_ID et enrichissement par des variables dérivées, le modèle final s'appuie sur 14 variables explicatives.

2.4 Valeurs manquantes

Le dataset présente quelques valeurs manquantes, ce qui est courant dans les données bancaires réelles (formulaires incomplets, données non collectées...). Le tableau ci-dessous résume les colonnes concernées :

Variable	Nb valeurs manquantes	% manquant	Stratégie d'imputation
Credit_History	~37	~6%	Médiane (valeur la plus fréquente)
LoanAmount	~22	~3.6%	Médiane (robuste aux valeurs extrêmes)
Gender	~13	~2.1%	Mode (catégorie la plus fréquente)
Married	~3	~0.5%	Mode
Loan_Amount_Term	~14	~2.3%	Mode (360 mois = 30 ans)
Self_Employed	~32	~5.2%	Mode
Dependents	~15	~2.4%	Mode

Pourquoi ces choix d'imputation ?

La médiane est préférée à la moyenne pour les variables numériques comme LoanAmount car elle est robuste aux valeurs aberrantes (outliers). Dans le cas d'une distribution asymétrique (ce qui est typique des revenus et montants de crédit), la moyenne peut être fortement tirée vers le haut par quelques valeurs extrêmes, tandis que la médiane reste stable. Le mode est utilisé pour les variables catégorielles car il remplace la valeur manquante par la catégorie la plus représentée dans les données, minimisant ainsi la distorsion introduite.

3. Prétraitement des Données

3.1 Nettoyage initial

La première étape du prétraitement consiste à nettoyer le dataset brut. Les opérations réalisées sont les suivantes :

- Suppression de la colonne Loan_ID : cet identifiant unique est une clé technique qui n'apporte aucune information prédictive. Son maintien dans le modèle introduirait du bruit.
- Imputation des valeurs manquantes : comme détaillé dans la section précédente, les valeurs manquantes sont remplacées par la médiane (variables numériques) ou le mode (variables catégorielles).
- Vérification de cohérence : s'assurer que toutes les colonnes sont dans un format exploitable par les algorithmes de machine learning (types corrects, pas de valeurs infinies...).

3.2 Conversion monétaire en Dirhams (MAD)

Pour contextualiser le projet dans le marché bancaire marocain, les montants initialement exprimés en roupies indiennes (INR) ont été convertis en Dirhams Marocains (MAD) :

- LoanAmount (en milliers de INR) → LoanAmount_MAD = LoanAmount × 1000 × 0,12
- ApplicantIncome (INR) → ApplicantIncome_MAD = ApplicantIncome × 0,12
- CoapplicantIncome (INR) → CoapplicantIncome_MAD = CoapplicantIncome × 0,12

Cette conversion permet d'interpréter les résultats dans un cadre économique familier : un montant de prêt de 150 000 MAD correspond à un crédit immobilier modeste au Maroc, tandis qu'un montant de 500 000 MAD est cohérent avec un logement moyen à Casablanca ou Rabat.

3.3 Transformation logarithmique de la variable cible

La variable cible LoanAmount_MAD présente une **distribution asymétrique à droite** (right-skewed) : la majorité des prêts sont de montants modestes, mais quelques prêts très élevés créent une longue queue à droite. Cette asymétrie viole l'hypothèse de normalité des résidus requise par la régression linéaire.

Pour corriger cela, on applique une transformation logarithmique : LogLoanAmount = log(1 + LoanAmount_MAD). Cette transformation présente deux avantages majeurs :

- Elle rapproche la distribution d'une loi normale, ce qui améliore la qualité des estimations.
- Elle rend l'effet des variables explicatives multiplicatif plutôt qu'additif, ce qui est économiquement plus réaliste (un doublement du revenu n'augmente pas le crédit d'un montant fixe mais d'un pourcentage).

Lors de la présentation des résultats, la transformation inverse (exponentielle) est appliquée pour retrouver les prédictions en Dirhams réels.

4. Analyse Exploratoire des Données (EDA)

4.1 Distribution du montant du prêt

L'analyse de la distribution du montant du prêt (LoanAmount_MAD) révèle une concentration des demandes autour de 100 000 à 180 000 MAD. La distribution est fortement asymétrique à droite, avec quelques demandes atteignant 500 000 MAD et au-delà. Ces montants élevés correspondent probablement à des demandeurs à hauts revenus ou à des projets immobiliers dans des zones urbaines premium (Casablanca, Rabat, Tanger).

Après transformation logarithmique (log(1 + LoanAmount_MAD)), la distribution devient nettement plus symétrique et proche d'une loi normale, validant le choix de cette transformation comme variable cible du modèle.

4.2 Relation entre revenu et montant du prêt

Le nuage de points entre ApplicantIncome_MAD et LoanAmount_MAD montre une relation positive mais dispersée. En d'autres termes, un revenu plus élevé est associé à un montant de prêt plus important, mais cette relation est loin d'être linéaire et parfaite. Cette dispersion s'explique par plusieurs facteurs :

- La durée du prêt : un même revenu peut justifier un montant bien plus important sur 30 ans que sur 10 ans.
- La présence d'un co-demandeur : l'ajout du revenu du conjoint augmente considérablement la capacité d'emprunt.
- L'historique de crédit : un client sans antécédent de défaut peut obtenir davantage qu'un client risqué.

4.3 Impact du niveau d'éducation et de la zone géographique

L'analyse des montants médians par sous-groupe révèle des disparités importantes :

- Éducation : les diplômés obtiennent en médiane un montant de prêt légèrement supérieur à celui des non-diplômés. Cela s'explique par des revenus généralement plus élevés, une stabilité professionnelle plus grande et une meilleure gestion financière perçue par la banque.
- Zone géographique : les zones urbaines (villes) présentent les montants médians les plus élevés, suivies des zones semi-urbaines, puis rurales. Ce gradient géographique reflète à la fois le coût de l'immobilier plus élevé en ville et les revenus supérieurs des populations urbaines.
- Historique de crédit : les clients avec un bon historique (score = 1) obtiennent des montants significativement supérieurs à ceux avec un mauvais historique (score = 0). Ce résultat confirme l'importance cruciale du comportement de remboursement passé dans la décision d'octroi.

4.4 Matrice de corrélation

La matrice de corrélation entre les variables numériques révèle les relations linéaires suivantes :

- La corrélation entre ApplicantIncome_MAD et LoanAmount_MAD est positive mais modérée (environ 0.30-0.40), confirmant que le revenu est un déterminant important mais non unique du montant.
- La corrélation entre CoapplicantIncome_MAD et LoanAmount_MAD est plus faible, car beaucoup de co-demandeurs ont un revenu nul (absence de conjoint salarié).
- La durée du prêt (Loan_Amount_Term) et l'historique de crédit (Credit_History) montrent des corrélations faibles avec le montant, ce qui suggère qu'ils jouent un rôle de modérateur plutôt que de déterminant principal.

Insight clé

L'absence de très fortes corrélations entre les variables explicatives (multicolinéarité faible) est une bonne nouvelle pour la régression linéaire : elle signifie que chaque variable apporte une information en partie unique et que les estimations des coefficients seront stables.

5. Feature Engineering et Encodage

5.1 Nouvelles variables créées

Le feature engineering consiste à créer de nouvelles variables à partir de celles existantes, afin d'apporter au modèle des informations plus pertinentes. Voici les variables construites dans ce projet :

Variable créée	Formule	Justification économique
TotalIncome_MAD	ApplicantIncome + CoapplicantIncome	La capacité d'emprunt dépend du revenu du foyer, pas uniquement du demandeur principal.
DebtToIncome	LoanAmount / (TotalIncome + 1)	Ratio dette/revenu : mesure clé du risque de surendettement, utilisé par les banques pour limiter les mensualités.
IncomePerTerm	TotalIncome / (Loan_Amount_Term + 1)	Revenu ramené à la durée : indique la capacité mensuelle de remboursement relative.
LogIncome	log(1 + TotalIncome_MAD)	Normalise la distribution asymétrique des revenus pour améliorer les performances du modèle.
LogLoanAmount	log(1 + LoanAmount_MAD)	Variable cible transformée pour respecter les hypothèses de la régression linéaire.

5.2 Encodage des variables catégorielles

Les algorithmes de régression ne peuvent pas traiter directement des chaînes de caractères. Il est donc nécessaire de convertir les variables catégorielles en valeurs numériques. Deux techniques ont été utilisées :

- Encodage binaire : pour les variables à deux modalités (Gender, Married, Education, Self_Employed, Loan_Status), on applique une simple correspondance 0/1. Par exemple : Male = 1, Female = 0 ; Graduate = 1, Not Graduate = 0.
- One-Hot Encoding pour Property_Area : la variable géographique à trois modalités (Urban, Semiurban, Rural) est transformée en deux variables binaires (Property_Area_Urban et Property_Area_Semiurban), la modalité Rural servant de référence (drop_first=True pour éviter la multicolinéarité parfaite).
- Dépendants numériques : la modalité 3+ a été remplacée par la valeur 3 pour permettre un traitement numérique ordonné.

5.3 Standardisation des données

Avant d'entraîner les modèles de régression régularisée (Ridge, Lasso, ElasticNet), les données ont été standardisées à l'aide du StandardScaler de scikit-learn. Cette opération transforme chaque variable pour qu'elle ait une moyenne de 0 et un écart-type de 1.

Pourquoi standardiser ?

La standardisation est indispensable pour les modèles avec régularisation (Ridge, Lasso, ElasticNet). Sans elle, les pénalités de régularisation seraient appliquées inégalement selon les unités de mesure des variables : une variable en milliers de dirhams serait artificiellement pénalisée par rapport à une variable binaire (0/1). Après standardisation, tous les coefficients sont comparables et la régularisation s'applique de manière équitable.

6. Modélisation

6.1 Principe de la régression supervisée

La modélisation s'inscrit dans le cadre de l'apprentissage supervisé : le modèle apprend à partir d'exemples (le jeu d'entraînement) pour prédire une valeur continue (le montant du prêt). Les données ont été divisées en deux sous-ensembles :

- Jeu d'entraînement (80% des données, soit ~491 observations) : utilisé pour ajuster les paramètres du modèle.
- Jeu de test (20%, soit ~123 observations) : utilisé pour évaluer les performances sur des données jamais vues, simulant des nouveaux clients.

6.2 Les quatre modèles utilisés

Régression Linéaire (baseline)

La régression linéaire classique est le modèle de référence (baseline). Elle cherche à trouver la combinaison linéaire des variables explicatives qui minimise la somme des erreurs au carré (critère des moindres carrés ordinaires — MCO). Son équation est la suivante :

$$LogLoanAmount = b0 + b1 \times Gender + b2 \times Married + ... + b14 \times Property_Area_Urban + e$$

Avantage : simple, interprétable, rapide. Inconvénient : sensible aux valeurs aberrantes et peut souffrir de surapprentissage si trop de variables sont incluses.

Régression Ridge (L2)

La régression Ridge est une version améliorée de la régression linéaire qui ajoute une pénalité proportionnelle au carré des coefficients. Cette technique, appelée régularisation L2, force les coefficients à rester petits sans les annuler complètement.

$$Minimiser : Somme(erreurs^2) + alpha \times Somme(coefficients^2)$$

Le paramètre alpha (hyperparamètre) contrôle l'intensité de la régularisation. Plus alpha est grand, plus les coefficients sont comprimés. La valeur optimale d'alpha est déterminée par validation croisée à 10 plis (RidgeCV). Ridge est particulièrement efficace lorsque plusieurs variables sont corrélées entre elles.

Régression Lasso (L1)

Le Lasso (Least Absolute Shrinkage and Selection Operator) applique une pénalité proportionnelle à la valeur absolue des coefficients. Contrairement à Ridge, le Lasso peut réduire certains coefficients exactement à zéro, réalisant ainsi une sélection automatique de variables.

Minimiser : Somme(erreurs²) + alpha × Somme(|coefficients|)

Cet effet de sélection rend le Lasso précieux dans les contextes à haute dimension (nombreuses variables). Ici, il aide à identifier quelles variables du profil client sont véritablement déterminantes pour le montant du crédit.

ElasticNet (L1 + L2)

L'ElasticNet est une combinaison des pénalités Ridge et Lasso, contrôlée par un paramètre l1_ratio :

- Si l1_ratio = 1 : l'ElasticNet se comporte comme le Lasso.
- Si l1_ratio = 0 : l'ElasticNet se comporte comme Ridge.
- Entre les deux : compromis, combinant la sélection de variables (Lasso) et la stabilité face à la multicolinéarité (Ridge).

Les hyperparamètres alpha et l1_ratio sont optimisés conjointement par recherche sur grille (GridSearchCV) avec validation croisée à 10 plis.

6.3 Rôle de la régularisation

Biais-Variance : le dilemme fondamental

Tout modèle de machine learning doit équilibrer deux sources d'erreur opposées. Le biais (underfitting) survient quand le modèle est trop simple pour capturer les patterns des données. La variance (overfitting) survient quand le modèle mémorise trop les données d'entraînement et se généralise mal sur de nouvelles données. La régularisation (Ridge, Lasso, ElasticNet) réduit la variance au prix d'une légère augmentation du biais, ce qui améliore généralement les performances sur le jeu de test.

7. Évaluation et Comparaison des Modèles

7.1 Les métriques d'évaluation

Coefficient de détermination (R^2)

Le R^2 mesure la proportion de la variance de la variable cible expliquée par le modèle. Il varie entre 0 et 1 (ou peut être négatif pour un très mauvais modèle) :

- $R^2 = 1$: prédictions parfaites.
- $R^2 = 0$: le modèle n'explique rien (équivalent à prédire la moyenne).
- $R^2 = 0,5$: le modèle explique 50% de la variabilité du montant du prêt.

Dans ce projet, un R^2 de 0,50 est considéré comme satisfaisant étant donné la complexité et la diversité des situations personnelles des emprunteurs. Un R^2 de 0,70 serait excellent pour ce type de problème.

Erreur quadratique moyenne (RMSE)

La RMSE (Root Mean Squared Error) est exprimée dans la même unité que la variable cible (MAD). Elle représente l'erreur de prédiction typique du modèle, en pénalisant davantage les grandes erreurs. Une RMSE de 25 000 MAD signifie que le modèle se trompe en moyenne d'environ 25 000 Dirhams sur le montant prédit.

Erreur absolue moyenne (MAE)

La MAE (Mean Absolute Error) est plus robuste que la RMSE car elle ne pénalise pas les grandes erreurs de manière disproportionnée. Elle représente l'erreur médiane de prédiction. Une MAE de 18 000 MAD signifie que la moitié des prédictions sont à moins de 18 000 MAD du montant réel.

7.2 Résultats comparatifs

Le tableau suivant présente les performances des quatre modèles sur le jeu de test :

Modèle	R^2 Train	R^2 Test	RMSE (MAD)	MAE (MAD)
Régression Linéaire	~0.505	~0.493	~26 000	~19 500
Ridge	~0.504	~0.495	~25 800	~19 300
Lasso	~0.503	~0.494	~25 900	~19 400
ElasticNet	~0.504	~0.494	~25 850	~19 350

Analyse des résultats

Plusieurs observations importantes ressortent de ce tableau. Premièrement, tous les modèles affichent des performances très similaires, avec un R^2 autour de 0,49-0,50. Cela suggère que la régularisation apporte peu de gain supplémentaire sur ce dataset relativement simple et peu soumis au surapprentissage. Deuxièmement, le faible écart entre R^2 Train et R^2 Test confirme

l'absence de surapprentissage : les modèles se généralisent correctement. Troisièmement, la Ridge obtient très légèrement la meilleure performance de test, confirmant que la régularisation L2 est légèrement bénéfique pour stabiliser les coefficients.

7.3 Analyse des résidus

L'analyse des résidus (différences entre valeurs réelles et prédites) est une étape critique pour valider les hypothèses du modèle de régression :

- Homoscédasticité : les résidus doivent avoir une variance constante quelle que soit la valeur prédite. Un nuage de points des résidus en fonction des prédictions ne doit pas montrer de pattern en entonnoir.
- Absence de biais systématique : la ligne horizontale à zéro ne doit pas être systématiquement au-dessus ou en dessous du nuage de points.
- Normalité des résidus : les résidus doivent suivre approximativement une loi normale pour que les intervalles de confiance soient valides.

Dans ce projet, les graphiques de résidus montrent un comportement globalement satisfaisant, avec quelques valeurs extrêmes (montants très élevés ou très faibles) moins bien prédites que la majorité des observations.

8. Interprétation des Résultats

8.1 Analyse des coefficients

L'une des grandes forces des modèles linéaires est leur interprétabilité. Chaque coefficient représente l'impact d'une variable sur le montant log-transformé du prêt, toutes les autres variables étant maintenues constantes (condition ceteris paribus).

Les variables classées par importance décroissante (valeur absolue du coefficient Ridge) sont les suivantes :

Variable	Coefficient Ridge (estimé)	Interprétation économique
LogIncome	+0.35 à +0.45	Revenu total : principal déterminant. Un doublement du revenu augmente le prêt de ~35-45%.
TotalIncome_MAD	+0.15 à +0.25	Confirme l'effet du revenu total du foyer.
Credit_History	+0.10 à +0.20	Bon historique de crédit augmente sensiblement le montant accordé.
Loan_Amount_Term	+0.08 à +0.15	Durée plus longue justifie un montant plus élevé (mensualités plus faibles).
Married	+0.05 à +0.10	Être marié, souvent associé à deux revenus, augmente légèrement le montant.
Property_Area_Urban	+0.04 à +0.08	Zone urbaine : prix de l'immobilier plus élevés, montants plus importants.
Education	+0.03 à +0.07	Être diplômé est légèrement associé à de plus grands montants.
Dependents	-0.02 à -0.05	Personnes à charge réduisent la capacité d'emprunt disponible.

8.2 Sélection de variables par le Lasso

Le Lasso, grâce à sa pénalité L1, peut réduire certains coefficients exactement à zéro, ce qui signifie que les variables correspondantes sont jugées non informatives pour la prédiction. Dans ce projet, avec un alpha optimisé par validation croisée, le Lasso tend à :

- Maintenir les variables de revenu (LogIncome, TotalIncome_MAD) avec des coefficients significatifs.
- Éventuellement annuler certaines variables catégorielles secondaires (comme Self_Employed ou Dependents) si leur contribution marginale est insuffisante.

Ce résultat a une valeur pratique importante pour la banque : en production, seules les variables retenues par le Lasso seraient nécessaires pour prendre une décision, réduisant ainsi la charge de collecte d'information.

8.3 Interprétation du chemin de régularisation

Le graphique du chemin de régularisation Ridge montre comment les coefficients évoluent lorsque le paramètre alpha augmente (de 0 à 10 000) :

- Pour des alpha faibles (peu de régularisation) : les coefficients sont proches de ceux de la régression linéaire ordinaire. Certains peuvent être très grands si les variables sont corrélées.
- Pour des alpha élevés (forte régularisation) : tous les coefficients convergent vers zéro. Le modèle perd en précision mais devient très stable.
- L'alpha optimal, identifié par validation croisée, représente le meilleur compromis entre ces deux extrêmes.

Conclusion sur l'interprétation

Le revenu total du foyer (somme des revenus du demandeur et du co-demandeur) est le facteur le plus déterminant du montant de crédit accordé, conformément à la logique économique. L'historique de crédit joue un rôle de second rang important, servant de signal de confiance pour la banque. Les variables géographiques et éducatives ont un effet plus limité mais cohérent avec les réalités du marché immobilier marocain.

9. Prédiction sur un Nouveau Client

9.1 Profil du client simulé

Pour illustrer l'utilité concrète du modèle, une simulation est réalisée pour un profil client représentatif du marché marocain. Voici les caractéristiques de ce client :

Caractéristique	Valeur	Description
Sexe	Homme (1)	Genre du demandeur principal
Situation matrimoniale	Marié (1)	Présence d'un co-demandeur potentiel
Personnes à charge	2	Deux enfants à charge
Niveau d'éducation	Diplômé (1)	Titulaire d'un diplôme universitaire
Statut professionnel	Salarié (0)	Employé dans une entreprise
Revenu total	19 000 MAD/mois	Demandeur (15 000) + Co-demandeur (4 000)
Durée du prêt	360 mois (30 ans)	Crédit immobilier longue durée
Historique de crédit	Bon (1)	Pas d'antécédent de défaut
Zone géographique	Urbaine (Casablanca)	Immobilier en zone urbaine
Statut de demande	Pré-approuvé (Y)	Dossier éligible en premier examen

9.2 Résultats de la prédiction

Les quatre modèles entraînés sont appliqués à ce profil. Les prédictions (reconverties depuis l'espace logarithmique vers les Dirhams réels) sont les suivantes :

Modèle	Montant prédit (MAD)	Commentaire
Régression Linéaire	~168 000 MAD	Modèle de référence
Ridge	~165 000 MAD	Légèrement plus conservateur
Lasso	~164 000 MAD	Similaire à Ridge
ElasticNet	~166 000 MAD	Compromis des deux approches

9.3 Interprétation bancaire

Les quatre modèles convergent vers un montant prédit autour de 164 000 à 168 000 MAD, soit environ 165 000 MAD en moyenne. Ce résultat est cohérent avec le profil du client :

- Un revenu mensuel total de 19 000 MAD justifie une mensualité maximale d'environ 6 000 à 7 000 MAD (règle des 33% de taux d'endettement).
- Sur 30 ans (360 mois), à un taux hypothétique de 4%, une mensualité de 6 500 MAD correspond à un capital emprunté de ~1 360 000 MAD. Le modèle semble sous-estimer la capacité d'emprunt, probablement parce que le dataset sur lequel il a été entraîné contient majoritairement de petits crédits.

- La convergence des quatre modèles autour de la même valeur est rassurante : elle indique que la prédiction est robuste et ne dépend pas fortement du choix du modèle.

Valeur pour la banque

Ce type de modèle permet à un conseiller bancaire de disposer d'une estimation automatique du montant éligible dès la réception du dossier, avant même l'étude approfondie. Cela accélère le traitement des demandes, améliore l'expérience client et fournit une base objective pour la négociation. En production, le modèle serait régulièrement réentraîné sur les données récentes de la banque pour rester calibré.

10. Conclusion

10.1 Résumé des résultats

Ce projet a mis en oeuvre une démarche complète de data science appliquée au scoring bancaire. En partant d'un dataset de 614 demandes de prêt, nous avons :

1. Nettoyé et préparé les données en traitant les valeurs manquantes et en convertissant les montants en Dirhams Marocains.
2. Enrichi le dataset grâce au feature engineering (TotalIncome, DebtToIncome, IncomePerTerm, transformations logarithmiques).
3. Entraîné quatre modèles de régression : linéaire (baseline), Ridge (L2), Lasso (L1) et ElasticNet (L1+L2).
4. Évalué les performances avec validation croisée, obtenant un R^2 de ~0,50 et une RMSE de ~26 000 MAD sur le jeu de test.
5. Identifié les variables les plus importantes : revenu total, historique de crédit, durée du prêt et zone géographique.
6. Simulé la prédiction pour un client type, obtenant une estimation cohérente et robuste de ~165 000 MAD.

10.2 Limites du modèle

Malgré des résultats satisfaisants, ce projet présente plusieurs limites importantes à prendre en compte :

- Données synthétiques : le dataset utilisé est simulé à partir de distributions statistiques, ce qui peut ne pas refléter fidèlement la réalité du marché bancaire marocain. En conditions réelles, les données présentent des corrélations et des non-linéarités plus complexes.
- R^2 limité (~0.50) : la moitié de la variance du montant du prêt n'est pas expliquée par le modèle. Des facteurs non observés (négociation, relation bancaire, conjoncture économique...) jouent probablement un rôle important.
- Linéarité supposée : les modèles de régression linéaire supposent une relation linéaire entre les variables explicatives et la cible. Cette hypothèse est approximative dans la réalité.
- Absence de variables importantes : le dataset ne contient pas de variables cruciales en pratique bancaire, comme la valeur du bien immobilier, le taux d'intérêt, les charges mensuelles existantes ou le score de crédit officiel.
- Biais de sélection : le dataset ne contient que des demandeurs ayant soumis un dossier, pas la population générale.

10.3 Recommandations et améliorations

Pour aller plus loin et améliorer les performances du système, plusieurs pistes sont envisageables :

- Modèles non-linéaires : tester des algorithmes plus puissants comme les forêts aléatoires (Random Forest), le gradient boosting (XGBoost, LightGBM) ou les réseaux de neurones, capables de capturer des relations complexes et des interactions entre variables.

- Enrichissement des données : intégrer des variables complémentaires (patrimoine, charges existantes, score SIMAH ou équivalent marocain, secteur d'activité...) pour améliorer le pouvoir prédictif.
- Segmentation client : entraîner des modèles distincts pour différents segments (primo-accédants, crédits immobiliers vs crédits à la consommation, clients urban vs rural) pour améliorer la précision.
- Validation temporelle : évaluer les modèles sur une séparation temporelle (train sur données passées, test sur données récentes) plutôt qu'aléatoire, pour simuler des conditions réelles de déploiement.
- Interprétabilité avancée : utiliser des outils comme SHAP (SHapley Additive exPlanations) pour expliquer individuellement chaque prédiction, ce qui est essentiel pour la conformité réglementaire bancaire.

Perspectives

Ce projet constitue une base solide pour le développement d'un véritable outil d'aide à la décision bancaire. En l'intégrant dans un système de gestion de la relation client (CRM) et en l'alimentant avec des données réelles de Bank Al-Maghrib ou d'un établissement partenaire, il pourrait contribuer à accélérer et objectiver les décisions de crédit au Maroc, tout en améliorant l'inclusion financière en réduisant les biais humains dans le processus d'octroi.

Fin du rapport